

SISTEMAS DE APOYO A LA DECISIÓN

GRADO EN INGENIERÍA INFORMÁTICA DE GESTIÓN Y SISTEMAS DE
INFORMACIÓN

Documentación del Modelo y Prompt Engineering

Autores:
Aitzol Rivera
María Fernández
Iván Salazar
Paula Tapias

Profesor:
Aitziber Atutxa Salazar

Bilbao, a 03 de mayo de 2026

ÍNDICE

1. Modelo Elegido: Llama 3 (8B)	3
2. Estrategias Probadas	3
3. Estrategia Final	4
4. Generación de Resultados	4

1. Modelo Elegido: Llama 3 (8B)

Para este proyecto hemos seleccionado el modelo Llama 3, ejecutado localmente a través de Ollama.

Lo hemos elegido por su excelente equilibrio entre precisión y requisitos de hardware para entender el sarcasmo o la ambigüedad en las reseñas de apps de citas.

Aunque modelos como Gemma 2 son muy rápidos, Llama 3 demostró una mayor consistencia al seguir instrucciones estrictas de formato, lo cual es crítico para generar el CSV final.

2. Estrategias Probadas

Durante la fase de experimentación hemos probado tres aproximaciones principales para encontrar la más robusta:

- **Clasificación Directa (Zero-shot):**
 - a. *Enfoque:* Le hemos dado al modelo la instrucción directa de clasificar sin ejemplos previos.
 - b. *Resultado:* El modelo ha entendido bien los extremos (muy positivo o muy negativo), pero fallaba en los comentarios neutros, clasificándolos como positivos de forma errónea.
- **Prompt de Rol:**
 - a. *Enfoque:* Le hemos asignado a la IA el rol de *"Analista de sentimientos experto en apps de citas"*.
 - b. *Resultado:* La precisión ha mejorado, ya que el modelo ha adoptado un tono más analítico y profesional, reduciendo la influencia de sesgos personales de la IA.
- **Few-shot (Estrategia Ganadora):**
 - a. *Enfoque:* Hemos incluido ejemplos representativos de cada clase dentro del prompt antes de realizar la consulta real.
 - b. *Resultado:* Ha sido la estrategia más exitosa. Al proporcionarle ejemplos de lo que consideramos "Neutro", el modelo ha aprendido a diferenciar la clase 1 de la 2 con mucha mayor precisión que los modelos tradicionales de Machine Learning.

3. Estrategia Final

Tras las iteraciones, el prompt exacto que mejores resultados ha dado en el conjunto de pruebas y que se ha implementado en el script `ollama_inference.py` es el siguiente:

Prompt: `"""Act as a sentiment analyst for a dating app company. Analyze the following comment and classify it strictly as: 0: Negative (bugs, bad experience, complaints) 1: Neutral (indifference, average experience, comparison to others) 2: Positive (loves the app, good experience, praises)`

Examples: 'I love this app' -> 2 'This app is terrible' -> 0 'It is just like the others' -> 1

Respond ONLY with the number (0, 1, or 2). Do not write anything else.

Comment: '{texto}' Prediction:""

4. Generación de Resultados

Para la generación del entregable final (**predicciones_generativas.csv**), hemos optado por realizar la inferencia sobre una muestra aleatoria de 100 reseñas extraídas del dataset original.

Dado que el procesamiento con modelos de lenguaje (LLM) es más costoso a nivel de recursos que los modelos tradicionales, una muestra de 100 reseñas permite validar la eficacia del *Prompt Engineering* diseñado sin comprometer la viabilidad técnica de la entrega.

Al utilizar una técnica de muestreo aleatorio (random sampling), se garantiza que la muestra contenga una distribución variada de sentimientos (positivos, negativos y neutros), evitando los sesgos que produciría elegir únicamente las primeras filas del archivo original (el cual se encontraba ordenado por puntuación).